

Semiparametric Gaussian Copula Graphical Model

황희정

서울대학교 정밀식의학연구실

[2025.11.25]

Gaussian Graphical Model(GGM)

목표: 직접 관계만 식별하여 진정한 구조 파악

$$X \sim N(\mu, \Sigma) \rightarrow \Theta = \Sigma^{-1}$$



핵심 아이디어

공분산 행렬(Σ)은 모든 관계(직접 + 간접)를 포함하지만, 정밀도 행렬(Θ)은 직접적인 관계만 나타냄.
정밀도 행렬만을 이용한 그래프 모델이 Gaussian Graphical Model (GGM)




Σ 계산

샘플 공분산 행렬



$\hat{\Theta} = \Sigma^{-1}$

정밀도 행렬 (역행렬)



임계치로 희소화

작은 값 $\rightarrow 0$ 으로




네트워크 시각화

그래프 구조 복원



$n < p$ 고차원 문제에서는 Σ 이 특이행렬(singular)이 되어 역행렬이 존재하지 않음.
이런 경우 Graphical Lasso와 같은 정규화 방법이 필요

그래프 구축 과정



정규분포란?

- 종 모양(Bell curve)의 연속 확률 분포
- 평균 주변에 데이터가 밀집, 좌우 대칭 구조
- 자연현상, 측정 오차, 생체 지표 등에서 빈번하게 관찰
- 표기: $X \sim N(\mu, \sigma^2)$ (μ : 평균, σ^2 : 분산)

❖ 평균 μ (Mean)


- 분포의 중심 위치
- 정규분포는 평균을 중심으로 좌우 대칭 구조

❖ 표준편차 σ (Standard Deviation)

- 데이터가 평균으로부터 퍼진 정도
- σ 작을수록: 좁고 뾰족한 형태
- σ 클수록: 넓고 완만한 형태

❖ 정규분포에서 데이터의 분포 범위

- $\mu \pm 1\sigma$: 약 68% 포함
- $\mu \pm 2\sigma$: 약 95% 포함
- $\mu \pm 3\sigma$: 약 99.7% 포함



● $\sigma = 0.5$ (좁고 뾰족) ● $\sigma = 1.0$ (표준 정규분포) ● $\sigma = 2.0$ (넓고 완만)

정규분포 기호

$$X \sim N(\mu, \sigma^2)$$

X

확률변수 (Random Variable)

측정하고자 하는 데이터를 나타내는 변수
예시: 키, 몸무게, 혈압 등

~

"분포를 따른다" (follows)

확률변수 X가 특정 확률분포를 따른다는 의미
"~"은 "분포를 따른다"라고 해석할 수 있음

N

정규분포 (Normal Distribution)

분포 종류 중 정규분포를 의미
다른 분포: Exp(지수), Bin(이항), U(균등) 등

μ, σ^2

모수 (Parameters)

μ (뮤): 평균
 σ^2 (시그마 제곱)

💡

예시

키 $\sim N(170, 100)$ $\rightarrow$ 키는 평균 170cm, 표준편차 10cm인 정규분포를 따릅니다.

다변량 정규분포

- 여러 변수가 동시에 정규분포를 따르는 확률 모형
- 각 변수는 서로 상관관계를 가지며 함께 변동함

p개 변수로 구성된 확률 벡터

평균 벡터 (각 변수의 평균값, p차원)

$$X = (X_1, X_2, \dots, X_p) \sim N(\mu, \Sigma)$$

공분산 행렬 (변수 간 관계 구조, p×p 행렬)

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix}$$

공분산(Covariance) 정의

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$$



수학적 정의

- 두 변수의 편차를 곱한 값의 평균
- 변수들이 평균으로부터 얼마나 함께 변동하는지 측정



해석

- 양의 값(+): 함께 증가/감소 (양의 관계)
- 음의 값(-): 반대 방향으로 변동 (음의 관계)
- 0에 가까움: 선형 관계 없음

공분산은 단위에 의존
값의 크기 자체는 관계의 강도를 직접 비교하기에 부적합
이를 해결하려면 **상관계수로 표준화** 필요

공분산 계산 예시

키와 몸무게 데이터

사람	키 (cm)	몸무게 (kg)
1	165	60
2	170	65
3	175	70
4	180	75
5	185	80
평균	175	70

편차와 곱

사람	키 편차 (x-평균)	몸무게 편차 (y-평균)	편차의 곱 (x-평균) (y-평균)
1	-10	-10	100
2	-5	-5	25
3	0	0	0
4	5	5	5
5	10	10	100
평균			50

공분산 계산 과정

- 1 평균 계산
- 키 평균: 175cm, 몸무게 평균: 70kg
- 2 편차 계산
- 예: 첫 번째 사람의 키 편차 = 165 - 175 = -10
- 3 편차 곱 계산
- 예: 첫 번째 사람 = (-10) × (-10) = 100
- 4 공분산 계산 (편차 곱의 평균)
- Cov(키, 몸무게) = 250 / 5 = 50

공분산 = 50 (양의 상관관계)

→ 공분산이 양수이므로, 키와 몸무게는 함께 증가하는 경향이 있다고 해석

공분산(Covariance) 해석 주의



공분산 값의 절댓값 자체는 의미 해석이 어려움

$Cov(X, Y)$

단위	공분산
키(cm)-몸무게(kg)	$Cov = 50.0$
키(m)-몸무게(kg)	$Cov = 0.5$

※ 키를 cm에서 m로 단위를 바꾸면 공분산이 100배 작아짐

서로 다른 변수 쌍의 공분산 값을 직접 비교하기 어려움

주 용도: 수학적 모델링

- 다변량 정규분포 정의
- 역행렬 계산(그래피컬 모델)
- 확률 계산 및 추론



Pearson 상관계수로 표준화

$\rho = Cov(X, Y) / (\sigma_X \times \sigma_Y)$

단위	상관계수
키(cm)-몸무게(kg)	$\rho = 0.85$
키(m)-몸무게(kg)	$\rho = 0.85$

※ 단위 변화에도 일관된 값을 보임

다른 변수쌍과 직접 비교 & 강도 해석 가능

주 용도: 해석과 보고

- 관계 강도 평가(약, 중간, 강함)
- 시각화 및 보고서 작성
- 특성 선택 및 중요도 평가

정규분포에 따른 공분산 행렬 계산 차이

A 전통적 GGM 워크플로우 (정규분포 가정)



정규성 가정 필요
이상치에 민감
실제 값 기반 계산

B Gaussian Copula 워크플로우 (비정규 허용)



정규성 가정 불필요
이상치에 강건
특수 변환 공식 사용

비정규성의 영향

- 실제 데이터는 정규분포를 따르지 않는 경우가 일반적
 - 치우침(skewed): 유전자 발현, 영양소 농도 등
 - 중도절단(censored): 검출한계 이하, 최댓값 제한 등
 - 이상치(outliers): 극단값, 측정 오류 포함
- 정규분포 가정 위반 시,
 - 공분산/피어슨 상관계수 왜곡
 - 이상치와 극단값에 지나치게 민감한 추정치 발생



Gaussian Copula

적절한 변환을 거쳐 구조 분포 가정을 완화하여 정규분포로 만드는 프레임워크

Nonparanormal SKEPTIC



Monotone Transformation
= Rank Transformation

$X \rightarrow \text{ranks}$

$$\hat{F}(x) = (\text{rank} - 0.5) / n$$



Marginal Uniformization
= Empirical CDF

$\text{ranks} \rightarrow u \in (0,1)$



Joint Normalization
= Quantile Transform

$u \rightarrow Z \sim N(0, \Sigma)$



공분산
행렬 추정

정밀도 행렬 Θ 추정

잠재 변수 이론 (Latent Variable Theory)

Ordinal 응답의 본질 $\rightarrow$ 실제 섭취량 연속, 관측 불가

응답자 1: 실제 섭취량 = 2.1회/주
응답자 3: 실제 섭취량 = 2.7회/주
응답자 5: 실제 섭취량 = 1.9회/주

$\downarrow$ 설문 척도로 이산화

모두 "2" (주 1-2회)로 기록

<문제>

원본 ordinal 값을 그대로
사용하면 정보 손실
(2라고 응답한 5명을
모두 동일하게 취급
 $\rightarrow$ 분산 과소추정)

Gaussian Copula 적용

원본: 응답자 1-10명의 Processed Foods 점수: [2, 3, 0, 1, 4, 2, 5, 1, 2, 3]

1 Step 1: Rank Transformation (22,944명 전체에서 순위 계산)

`ranks = [5432, 12341, 234, 2341, 18234, 5433, 22100, 2342, 5434, 12342]` # 동점자는 평균 순위 부여

2 Step 2: Empirical CDF (Winsorization)

$$\hat{F}(x) = (\text{rank} - 0.5) / n = (\text{rank} - 0.5) / 22,944$$

응답자 1: $\hat{F} = (5432 - 0.5) / 22,944 = 0.2367$
응답자 2: $\hat{F} = (12341 - 0.5) / 22,944 = 0.5378$
응답자 3: $\hat{F} = (234 - 0.5) / 22,944 = 0.0102$
...

3 Step 3: Quantile Transformation (Φ^{-1})

$$Z = \Phi^{-1}(\hat{F}) \text{ \# 표준정규분포의 역함수}$$

응답자 1: $Z = \Phi^{-1}(0.2367) = -0.718$
응답자 2: $Z = \Phi^{-1}(0.5378) = 0.095$
응답자 3: $Z = \Phi^{-1}(0.0102) = -2.319$
...

공분산 행렬 → 정밀도 행렬



공분산 행렬 (Σ)

전체 효과를 보여줌 (직접 관계 + 간접 관계)

	X ₁ 비타민C	X ₂ 철분	X ₃ 헤모글로빈
X ₁ 비타민C	100	40	15
X ₂ 철분	40	150	60
X ₃ 헤모글로빈	15	60	200

변수 쌍	공분산	관계
비타민C - 철분	40	양의 상관관계 강함
철분 - 헤모글로빈	60	양의 상관관계 강함
비타민C - 헤모글로빈	15	양의 상관관계 약함




정밀도 행렬 ($\Theta = \Sigma^{-1}$)

직접 효과만 보여줌 (다른 모든 변수를 통제했을 때의 순수 관계)

	X ₁ 비타민C	X ₂ 철분	X ₃ 헤모글로빈
X ₁ 비타민C	0.012	-0.003	0
X ₂ 철분	-0.003	0.009	-0.004
X ₃ 헤모글로빈	0	-0.004	0.007

(비타민C와 헤모글로빈은 철분을 통해서만 관련됨)



- 그래프 구조 정확히 식별
- 직접 경로와 간접 경로 구분 가능
- 정밀한 인과관계 추론의 기초
- 공분산보다 네트워크 해석에 적합

조건부 독립성

$$X_i \perp X_j \mid X_{-(i,j)}$$

⊥ 조건부 독립 기호

"조건부 독립"을 의미
 X_i 와 X_j 가 $X_{-(i,j)}$ 조건하에서 독립적이라는 뜻

| "주어졌을 때" (given)

조건부 확률에서 "~가 주어졌을 때"라는 의미
세로 막대 오른쪽의 조건이 성립한다는 가정을 나타냄

$X_{-(i,j)}$ 나머지 변수들

X_i 와 X_j 를 제외한 모든 다른 변수를 의미
 $X_1, X_2, \dots, X_p$ 중에서 X_i 와 X_j 를 제외한 변수들의 집합

💡 정밀도 행렬과의 관계

$\Theta_{ij} = 0 \iff X_i \perp X_j \mid X_{-(i,j)}$
정밀도 행렬의 (i,j) 원소가 0이면 해당 변수쌍은 조건부 독립

역행렬이 불가능한 경우



문제

변수 수(p) >> 샘플 수(n) → 표본공분산 행렬 Σ 가 full-rank가 아님



해결

고차원 데이터($p > n$)에서는 기존 방식으로 정밀도 행렬($\Theta = \Sigma^{-1}$)을 계산할 수 없음. → **정규화** 방법 필요



모델링 목표

정밀도 행렬 Θ 를 희소(sparse)하게 추정하여 중요한 연결만 남기고 나머지는 0으로 만들기

Graphical Lasso(Glasso)

$$\text{minimize: } -\log \det(\Theta) + \text{tr}(S\Theta) + \lambda \|\Theta\|_1$$

" Θ 가 0 행렬이 되면 안 돼!"

1 $-\log \det(\Theta)$: 로그 행렬식 (log-determinant)

- 행렬식: 주대각선의 곱 빼기 부대각선의 곱
- 역행렬이 존재하기 위해서는 $\det(\Theta) > 0$ 이어야 함.
- $-\log$ 를 취해줌으로써 ∞ 로 보내 페널티를 크게 할 수 있음.

"데이터를 설명해야 해!"

2 $\text{tr}(S\Theta)$: 트레이스

- 트레이스 = 행렬의 대각선 원소들의 합
- S : 실제 데이터에서 계산한 공분산 행렬
 Θ : 추정하려는 정밀도 행렬 (역공분산 행렬)

"너무 복잡하면 안 돼!"

3 $\lambda \|\Theta\|_1$

- $\|\Theta\|_1 =$ 행렬의 모든 원소의 절댓값
- $\lambda \|\Theta\|_1$ 페널티 때문에 Θ 의 많은 원소가 0이 됨

Θ 정밀도 행렬(Precision Matrix) 추정

- Θ 행렬 값을 임의로 설정한 다음에 한 행/열씩 순서대로 업데이트 (Block Coordinate Descent)하면서 위 식을 최소화시킴